

Алексей Забелин

AI-инженер · агенты, RAG, инференс

Хойан, Вьетнам (UTC+7) · удалённо · на связи в часах MSK, EU, UK и APAC
alekseyzabelin@gmail.com · Telegram @alekseyzabelin · linkedin.com/in/alekseyzabelin

КРАТКО

Строю агентов, которые работают сами, измеряю, что они делают на самом деле, и называю цифру вслух, даже когда она хуже прежней.

Единственный инженер-владелец SaaS-платформы на AWS: LLM-слой веду сам — function calling против production API, self-hosted retrieval и провайдерская лестница, которая переживает отказ прямо посреди прогона. Последний агент отработал 3 271 живое сообщение и закрыл 98,3% диалогов без человека; потом я нашёл, что моя же метрика завышена примерно на 20%, исправил её и опубликовал меньшее число. Вторая половина — двадцать лет поставки корпоративным заказчикам: я сажусь с отделом, которому принадлежит проблема, и выясняю, нужен ли там агент вообще.

СТЕК

Агенты и LLM — function calling / tool use, оркестрация агентов и конечные автоматы состояний, версионизируемые промпты, RAG над векторными хранилищами (Supabase / Postgres + pgvector), роутинг провайдеров с failover (Claude основной, OpenAI и Kimi), self-hosted развёртывание моделей (AnythingLLM в Docker), структурированный JSON-вывод с намерением и оценкой уверенности

Инференс и локальные модели — self-hosted инференс на Ollama с GGUF-квантованными весами, бенчмарки конкурентности и латентности, обрезка промпта и контекстного окна, ablation reasoning-режима, стоимость строки против облачного baseline

Оценка и измерения — учёт knowledge gaps с состоянием открыт/закрыт, анализ эскалаций, простановка провайдера и модели в каждом сообщении для трассируемости, рубрики со скорингом моделью против бесплатного эвристического baseline, pandas / NumPy / SciPy для разбора результатов

Бэкенд и интеграции — Python, TypeScript, JavaScript, SQL, Bash · Node.js, Express, проектирование REST API, вебхуки, интеграции сторонних API (amoCRM, Wazzup), OAuth / STS

Облако и доставка — AWS (EC2, S3, CloudFront, IAM, STS, WAF, Route 53), Cloudflare Workers и D1, Docker, GitHub Actions CI/CD с health-gated деплоем, мониторинг и алертинг продакшена, nginx, PM2, systemd

Данные — PostgreSQL / Supabase, MongoDB / DocumentDB, D1, Redis-очереди

АГЕНТЫ, КОТОРЫЕ Я ПОСТРОИЛ, И ЧТО ОНИ ПОКАЗАЛИ

Исходящий агент продаж — живая кампания · май 2026 · подряд для бизнеса на курсах маркетинга 13 активных дней, **3 271 сообщение, 471 лид**, 223 втянуты в диалог. **99,5% реплик лида отвечены, 98,3% закрыты без человека**, одна эскалация на 57 реплик. Каждая реплика отдавала структурированный JSON с намерением купить/отказаться, оценкой уверенности и флагом knowledge gap, поэтому вопросы, на которые агент не смог ответить, всплывали как данные, а не как тишина. Эскалации превратились в закрываемый бэклог: ~17–19 тем, каждая закрыта после ответа. Мои: промпт, база знаний, классификация намерений, пайплайн лидов в amoCRM/Wazzup, темп отправки, диагностика сбоев и все измерения. Работало на стороннем оркестраторе заказчика, не на моём коде.

Исправление. Я разделил «ответ ушёл» и «человек не понадобился» и обнаружил, что ключевое слово эскалации завышало счёт примерно на 20%: агент начинал собственные уточняющие вопросы той же фразой. Отфильтровал и опубликовал исправленное число.

marketing-worker — оркестратор, переписанный как мой код · авг 2026 — настоящее время Cloudflare Workers и D1: конечный автомат лида, версионизируемые промпты, темп отправки и расписание напоминаний, **лестница LLM-провайдеров — Claude основной, OpenAI и Kimi на отказ — с провайдером и моделью, проставленными в каждом сообщении.** 75/75 тестов, typoscheck чистый. Боевой трафик пока не несёт.

Агент с function calling против production API CMS · IGOTOPIA

Выполняет Python против живого API платформы. Не-инженеры теперь делают в диалоге то, что раньше требовало разработчика. Деструктивные пути наружу не выведены, каждый вызов логируется с моделью и параметрами.

Self-hosted RAG-агент поддержки · IGOTOPIA

AnythingLLM в Docker, retrieval по базе знаний и документам компании, модель обслуживается внутри нашей инфраструктуры.

Спайк по локальному инференсу — что показали замеры · сен 2026 · собственный инструмент Прогнал пайплайн скоринга на локальной модели в Ollama с GGUF-квантованными весами, чтобы проверить, покупают ли что-нибудь облачные расходы. **Латентность строки 7,5 с → 2,1 с** после обрезки промпта и контекста. Конкурентность дала **+16%** и упёрлась в потолок unified memory — значит, не ответ. Выключение reasoning сломало извлечение, а не только рубрику: результат, который лучше знать до выката. Главное: **бесплатная эвристика ранжирования дала корреляцию $r=0,536$ против 0,163 у модели**, поэтому ранжирование стало стоить ноль, а бюджет модели ушёл туда, где она действительно сильнее.

IGOTOPIA (Gecko Digital) — Малайзия

март 2022 – настоящее время · SaaS виртуальных туров для люксовой гостиничной индустрии, AWS Singapore

Platform & AI Engineer, владелец продукта · дек 2023 – настоящее время

Удалён из Вьетнама · единственный инженер-владелец платформы Lushlist с апр 2026

- **Веду платформу целиком** — продакшен и staging, четыре репозитория, 158 коммитов за пять месяцев. Одновременно владелец продукта: декомпозирую задачи и направляю двух джунов и коллегу из операций.
- **Внедрил агентов выше в реальный бизнес** — и решил, где им не место.
- **Заменял правки-на-проеде обратимыми релизами** — построил первое staging-окружение (изолированные EC2, база, префиксы S3, Redis) и GitHub Actions CI/CD для трёх приложений с health-gated деплоем. Написал ~35 ранбуков.
- **Сделал бесплатный мониторинг продакшена с управляемым самовосстановлением** — 60-секундный сторож на хосте, dead-man's switch, алерты в Telegram. Неделю держал в режиме только-алерты, затем включил автоматическое восстановление за пятислойной защитой.
- **Провёл аудит безопасности production API на 34 находки.** Каждая находка с доказательством file:line, исправлением и оценкой радиуса поражения. Довёл топ-11 (4 критических, 6 высоких) до обратимых фиксов и закрыл утечку доступов по семи классам секретов.
- **Провёл discovery, скоупинг и приёмку white-label сборки** с внешней командой 3–5 человек. Снял требования, написал спецификацию и план вех, принял поставку.

krPano-разработчик, аналитика виртуальных туров · март 2022 – дек 2023

- Python-автоматизация и пайплайны данных для обработки и публикации панорам.
- **Снизил время загрузки тура до ~3,1 с** с 4,7–7 с. Бенчмарки хостинга и настроек плеера против PageSpeed Insights API, разбор прогонов в pandas / NumPy / SciPy, чтобы выделить, что двигает Largest Contentful Paint, и настройка доставки под цель 2,5 с.

Polyglot Live — polyglot-talk.ai.studio

2026 · Сделано для **AI Riser Vietnam 2026** — синхронный перевод речи для живых докладов: речь на входе определяется автоматически, на выходе переведённые аудио и текст, раздача на телефоны слушателей или экран зала по одной ссылке сессии. На Gemini.

Разработчик 360°-пайплайна — НТЦ «3DFAB»

дек 2019 – янв 2022 · Санкт-Петербург

360°-продакшен для **учебных центров РЖД**. Написал инструмент предсшивки на Python/OpenCV: сопоставлял контрольные точки, отбрасывал совпадения за порогом различия и отдавал готовый проект PTGui — ручная сшивка превратилась в проход проверки. *Рекомендация от Константина Константинова, основателя и CEO.*

Фриланс — 360°-фотограф и krPano-разработчик

сен 2015 – дек 2019 · Санкт-Петербург

Панорамная съёмка, сшивка и разработка туров напрямую конечным заказчикам, каждый проект от брифа до опубликованного тура.

ОБРАЗОВАНИЕ И СЕРТИФИКАТЫ

Яндекс Практикум — «Специалист по Data Science» · март 2022 – дек 2023

Машинное обучение, статистика, анализ и визуализация данных на Python.

СПбГУТ им. проф. М. А. Бонч-Бруевича · 2000 – 2004

Диплом с отличием — техник, многоканальные телекоммуникационные системы.

Google Analytics Certification · 2024

ЯЗЫКИ

Русский — родной · английский — professional working proficiency

ИНТЕРЕСЫ

Визуализация данных · фотограмметрия · встраиваемая электроника (Arduino, ESP32, Raspberry Pi Pico) · 360°- и пейзажная фотография · хайкинг и долгие треки · випассана